УНИВЕРСИТЕТ ИТМО

Факультет инженерии искусственного интеллекта

Дисциплина «Инженерия данных»

Обеспечение отказоустойчивости средствами Apache ZooKeeper

Отчёт по домашнему заданию

Выполнил студент 3 курса
Волков Владимир Алексеевич
Группа J3313

Санкт-Петербург
2026

1 Цель работы и подготовка

В этой работе я развернул ансамбль из трёх серверов Apache ZooKeeper и подключил к нему две копии координатора расчёта пар навыков из ДЗ № 3. Проверил работу при потере серверов, исчезновение эфемерного узла и восстановление расчёта после приостановки лидера. В двух опытах сравнил публикацию результата без защиты и с проверкой эпохи.

Для развёртывания выбрал Docker Compose на macOS. Использовал образ zookeeper:3.9.6-jre-17, поэтому Java 17 работает внутри контейнеров. Координатор запускал локально под Python 3.12.14 с библиотекой Kazoo 2.11.0. Конфигурация трёх серверов сохранена в compose.yaml.

2 Настройка ансамбля

Сервер	myid	Порт на Mac	Каталог данных на Mac
zk1	1	2181	state/zk1/data
zk2	2	2182	state/zk2/data
zk3	3	2183	state/zk3/data

У каждого контейнера свой каталог /data и отдельный журнал транзакций /datalog. Они подключены к разным папкам state/zk1, state/zk2 и state/zk3. Значение ZOO_MY_ID задаёт номер сервера; образ создаёт соответствующий файл /data/myid.

Список участников ZOO_SERVERS одинаковый во всех трёх сервисах:

```
server.1=zk1:2888:3888;2181
server.2=zk2:2888:3888;2181
server.3=zk3:2888:3888;2181
```

Порт 2888 используется для взаимодействия лидера с последователями, порт 3888 — для выбора лидера. Внутри контейнеров клиентский порт одинаковый, 2181; на компьютере он опубликован как 2181, 2182 и 2183. Раздельные контейнеры и папки исключают конфликт портов и перезапись данных друг друга.

```
docker compose up -d
docker compose ps
docker compose exec -T zk1 zkServer.sh status
```

Проверку zkServer.sh status выполнил для каждого сервера. Выводы команд сохранял через tee в папку logs, а результаты дополнительно фиксировал скриншотами. Все серверы работают на одном компьютере: в работе моделируется отказ отдельных процессов, а не отказ всей машины.

3 Проверка ролей серверов

После запуска zk3 стал лидером, а zk1 и zk2 — последователями. Таким образом, три контейнера образовали ансамбль с одним лидером. Проверка показана на рисунке 1.

```
volkov@MacBook-Air-Vladimir-2 zk-homework % docker compose ps | tee logs/01-containers.txt
NAME                IMAGE                     COMMAND                  SERVICE   CREATED              STATUS              PORTS
zk-homework-zk1-1   zookeeper:3.9.6-jre-17   "/docker-entrypoint.…"   zk1       About a minute ago   Up About a minute   127.0.0.1:2181->2181/tcp
zk-homework-zk2-1   zookeeper:3.9.6-jre-17   "/docker-entrypoint.…"   zk2       About a minute ago   Up About a minute   127.0.0.1:2182->2181/tcp
zk-homework-zk3-1   zookeeper:3.9.6-jre-17   "/docker-entrypoint.…"   zk3       About a minute ago   Up About a minute   127.0.0.1:2183->2181/tcp
volkov@MacBook-Air-Vladimir-2 zk-homework % docker compose exec -T zk1 zkServer.sh status 2>&1 | tee logs/02-zk1-status.txt
ZooKeeper JMX enabled by default
Using config: /conf/zoo.cfg
Client port found: 2181. Client address: localhost. Client SSL: false.
Mode: follower
volkov@MacBook-Air-Vladimir-2 zk-homework % docker compose exec -T zk2 zkServer.sh status 2>&1 | tee logs/03-zk2-status.txt
ZooKeeper JMX enabled by default
Using config: /conf/zoo.cfg
Client port found: 2181. Client address: localhost. Client SSL: false.
Mode: follower
volkov@MacBook-Air-Vladimir-2 zk-homework % docker compose exec -T zk3 zkServer.sh status 2>&1 | tee logs/04-zk3-status.txt
ZooKeeper JMX enabled by default
Using config: /conf/zoo.cfg
Client port found: 2181. Client address: localhost. Client SSL: false.
Mode: leader
```

Рисунок 1 — Запущенные контейнеры и роли серверов ZooKeeper

Состояние	zk1	zk2	zk3
После первого запуска	follower	follower	leader
После восстановления ансамбля	follower	leader	follower

После остановки двух серверов и их последующего запуска лидерство перешло к zk2. Поэтому роль лидера не закреплена за одним контейнером постоянно. Первичные выводы сохранены в logs/02-zk1-status.txt — logs/04-zk3-status.txt; состояние после восстановления — в logs/16-restored-zk1.txt — logs/18-restored-zk3.txt.

4 Работа при потере одного сервера

Сначала остановил последователя zk1 командой docker compose stop zk1. Серверы zk2 и zk3 продолжили работать: один остался последователем, второй — лидером. Два участника из трёх сохраняют кворум.

```
volkov@MacBook-Air-Vladimir-2 zk-homework % docker compose stop zk1 2>&1 | tee logs/05-stop-zk1.txt
 Container zk-homework-zk1-1 Stopping
 Container zk-homework-zk1-1 Stopped
volkov@MacBook-Air-Vladimir-2 zk-homework % docker compose ps -a | tee logs/06-one-down-containers.txt
NAME               IMAGE                     COMMAND                  SERVICE   CREATED         STATUS                       PORTS
zk-homework-zk1-1   zookeeper:3.9.6-jre-17   "/docker-entrypoint.…"   zk1       4 minutes ago   Exited (143) 6 seconds ago
zk-homework-zk2-1   zookeeper:3.9.6-jre-17   "/docker-entrypoint.…"   zk2       4 minutes ago   Up 4 minutes                 127.0.0.1:2182->2181/tcp
zk-homework-zk3-1   zookeeper:3.9.6-jre-17   "/docker-entrypoint.…"   zk3       4 minutes ago   Up 4 minutes                 127.0.0.1:2183->2181/tcp
volkov@MacBook-Air-Vladimir-2 zk-homework % docker compose exec -T zk2 zkServer.sh status 2>&1 | tee logs/07-one-down-zk2.txt
ZooKeeper JMX enabled by default
Using config: /conf/zoo.cfg
Client port found: 2181. Client address: localhost. Client SSL: false.
Mode: follower
volkov@MacBook-Air-Vladimir-2 zk-homework % docker compose exec -T zk3 zkServer.sh status 2>&1 | tee logs/08-one-down-zk3.txt
ZooKeeper JMX enabled by default
Using config: /conf/zoo.cfg
Client port found: 2181. Client address: localhost. Client SSL: false.
Mode: leader
```

Рисунок 2 — Остановка zk1 и проверка ролей оставшихся серверов

Затем через zkCli на zk2 создал узел /quorum-check со значением one-server-down и прочитал его. Успешная запись и чтение подтверждают, что ансамбль обслуживает запросы при потере одного участника.

```
volkov@MacBook-Air-Vladimir-2 zk-homework % docker compose ps -a --format 'table {{.Service}}\t{{.Status}}'
SERVICE   STATUS
zk1       Exited (143) 5 minutes ago
zk2       Up 9 minutes
zk3       Up 9 minutes
volkov@MacBook-Air-Vladimir-2 zk-homework % grep -H 'Mode:' logs/07-one-down-zk2.txt logs/08-one-down-zk3.txt
logs/07-one-down-zk2.txt:Mode: follower
logs/08-one-down-zk3.txt:Mode: leader
volkov@MacBook-Air-Vladimir-2 zk-homework % grep -H '^Created /quorum-check$' logs/09-one-down-create.txt
logs/09-one-down-create.txt:Created /quorum-check
volkov@MacBook-Air-Vladimir-2 zk-homework % grep -H '^one-server-down$' logs/10-one-down-get.txt
logs/10-one-down-get.txt:one-server-down
```

Рисунок 3 — Успешное создание и чтение узла при остановленном zk1

5 Потеря двух серверов и восстановление

Не запуская zk1, остановил zk2. В работе остался только zk3. Команда zkServer.sh status выдала Error contacting service, а новый клиент с тайм-аутом 5000 мс завершился с ConnectionLoss. Контейнер zk3 оставался запущенным, но без большинства ансамбль не обслуживал запросы.

```
volkov@MacBook-Air-Vladimir-2 zk-homework % cat logs/12-two-down-containers.txt
SERVICE   STATUS
zk1       Exited (143) 9 minutes ago
zk2       Exited (143) 26 seconds ago
zk3       Up 14 minutes
volkov@MacBook-Air-Vladimir-2 zk-homework % grep -F 'Error contacting service' logs/13-two-down-status.txt
Error contacting service. It is probably not running.
volkov@MacBook-Air-Vladimir-2 zk-homework % grep -m 1 -o 'KeeperErrorCode = ConnectionLoss' logs/14-two-down-get.txt
KeeperErrorCode = ConnectionLoss
```

Рисунок 4 — Состояние при остановленных zk1 и zk2 и ошибка клиента

После этого выполнил docker compose start zk1 zk2. Проверка снова показала одного лидера и двух последователей. Чтение /quorum-check вернуло прежнее значение one-server-down. Данные сохранились, а доступность ансамбля восстановилась.

6 Проверка эфемерного узла

Во втором окне терминала открыл zkCli и создал узел командой create -e /ephemeral-check alive. Пока эта сессия была открыта, другой клиент видел значение alive и ненулевой ephemeralOwner = 0x10000151f720000. Идентификатор совпал с сессией создавшего узел клиента.

Завершил сессию владельца командой quit. Повторный запрос из другого окна вернул Node does not exist: /ephemeral-check. Это подтвердило, что узел удаляется при завершении создавшей его сессии.

```
volkov@MacBook-Air-Vladimir-2 zk-homework % grep -H -E 'Created /ephemeral-check|Session: .* closed' logs/20-ephemeral-o
wner.txt
logs/20-ephemeral-owner.txt:[zk: localhost:2181(CONNECTED) 0] Created /ephemeral-check
logs/20-ephemeral-owner.txt:2026-11-06 11:11:08,429 [myid:] - INFO  [main:o.a.z.ZooKeeper@1230] - Session: 0x10000151f72
0000 closed
volkov@MacBook-Air-Vladimir-2 zk-homework % grep -H -E '^alive$|^ephemeralOwner' logs/21-ephemeral-before.txt
logs/21-ephemeral-before.txt:alive
logs/21-ephemeral-before.txt:ephemeralOwner = 0x10000151f720000
volkov@MacBook-Air-Vladimir-2 zk-homework % grep -H -F 'Node does not exist: /ephemeral-check' logs/22-ephemeral-after.t
xt
logs/22-ephemeral-after.txt:Node does not exist: /ephemeral-check
```

Рисунок 5 — Создание эфемерного узла и его исчезновение после закрытия сессии

7 Расчёт пар навыков и чекпоинт

В качестве расчёта использовал задачу из ДЗ № 3 для варианта C/C++. Исходный CSV содержит 68 770 вакансий. Функции is_variant и parse_skills взял из source_tools.py. После отбора остаётся 869 вакансий. Навыки очищаются, приводятся к нижнему регистру и удаляются повторы; пары строятся через combinations(skills, 2).

Перед опытами выполнил coordinator.py baseline. Получил 6 800 уникальных пар и сумму их частот 13 468. Результат сравнивается с counts_k2.csv побайтово; проверка вернула equal_to_hw3: true.

```
volkov@MacBook-Air-Vladimir-2 zk-homework % .venv/bin/python coordinator.py baseline | tee logs/23-baseline.txt
{
  "source_rows": 68770,
  "selected_rows": 869,
  "unique_pairs": 6800,
  "pair_contributions": 13468,
  "sha256": "db3fb5953e52b8316ce2c1e9d158e1e1b356bdc0f88e487505ce4bb94f2b61f9",
  "equal_to_hw3": true
}
```

Рисунок 6 — Контрольный расчёт и совпадение с эталоном ДЗ № 3

Исходный CSV оставил в каталоге data предыдущей работы hh-cpp-mapreduce-lab. Эталон counts_k2.csv находится в текущем проекте. Функция verify_result не допускает публикацию, если CSV отличается от эталона. Совпадение подтверждено для обоих координаторов в обоих опытах.

Координаторы A и B подключаются к ансамблю с тайм-аутом сессии 10 секунд. В каждом журнале события session запрошенное и согласованное значения равны 10000 мс. Лидер выбирается атомарной транзакцией: координатор проверяет текущую эпоху, увеличивает её и создаёт эфемерный узел leader. Второй процесс ожидает освобождения лидерства.

Расчёт разбит на чанки по 1000 исходных строк. После чанка в checkpoint сохраняются номер следующей строки, количество отобранных вакансий и накопленные частоты пар. Хеш входного файла сохраняется при init в настройках опыта и проверяется при запуске каждой копии. Чекпоинт обновляется с проверкой эпохи в обоих режимах.

Для этого датасета полный чекпоинт занимает 260 534 байта, поэтому он хранится непосредственно в ZooKeeper. После смены лидера B загружает накопленные частоты и продолжает с next_row, не суммируя уже обработанные строки повторно. В обоих опытах он восстановился с позиции 10 000.

8 Приостановка лидера без защиты по эпохе

Создал опыт unsafe при FENCING=0 и запустил A и B. После сохранения чекпоинтов приостановил лидера A сигналом SIGSTOP. Остановился весь процесс, включая heartbeat. По истечении сессии B получил эпоху 2, продолжил с позиции 10 000 и первым опубликовал результат. После SIGCONT старый A завершил расчёт со своей эпохой 1 и также записал указатель.

```
volkov@MacBook-Air-Vladimir-2 zk-homework % grep '"event":"restored"' logs/unsafe-B.log
grep '"event":"записал результат"' logs/unsafe-A.log logs/unsafe-B.log
{"event":"restored","time":"2026-11-06T23:23:35.202099+00:00","mono_ns":301351316557166,"pid":32198,"worker":"B","epoch":2,"next_row":10000}
logs/unsafe-A.log:{"event":"записал результат","time":"2026-11-06T23:24:16.546256+00:00","mono_ns":301392661224666,"pid":32189,"worker":"A","epoch":1,"pointer_version":2}
logs/unsafe-B.log:{"event":"записал результат","time":"2026-11-06T23:23:49.175006+00:00","mono_ns":301365289623833,"pid":32198,"worker":"B","epoch":2,"pointer_version":1}
```

Рисунок 7 — Восстановление B с чекпоинта и две успешные публикации без защиты

```
volkov@MacBook-Air-Vladimir-2 zk-homework % cat logs/28-unsafe-final.txt
{
  "run": "unsafe",
  "fencing": 0,
  "pointer_version": 2,
  "pointer": {
    "worker": "A",
    "epoch": 1,
    "csv": "results/unsafe/db3fb5953e52b8316ce2c1e9d158e1e1b356bdc0f88e487505ce4bb94f2b61f9.csv",
    "source_rows": 68770,
    "selected_rows": 869,
    "unique_pairs": 6800,
    "pair_contributions": 13468,
    "sha256": "db3fb5953e52b8316ce2c1e9d158e1e1b356bdc0f88e487505ce4bb94f2b61f9",
    "equal_to_hw3": true
  },
  "csv_equal_to_hw3": true,
  "failover_seconds": 11.094586708,
  "accepted_writes": 2,
  "stale_publication_rejected": false,
  "pause_seconds": 40.156821708
}
```

Рисунок 8 — Итог опыта unsafe с версией указателя 2 и автором A

Лидер сменился за 11,095 с, пауза A составила 40,157 с. Приняты две публикации. Указатель B с эпохой 2 перезаписан указателем A с устаревшей эпохой 1. При этом оба расчёта совпали с эталоном. Подтверждения сохранены в logs/unsafe-A.log, logs/unsafe-B.log и logs/28-unsafe-final.txt.

9 Приостановка лидера с защитой по эпохе

Повторил сценарий в отдельном опыте fenced, созданном при FENCING=1. B снова получил эпоху 2 и восстановился с позиции 10 000. После возобновления A попытался отправить результат со старой эпохой 1. Получатель отклонил изменение указателя с BadVersionError, поэтому опубликованным остался результат B.

```
volkov@MacBook-Air-Vladimir-2 zk-homework % grep '"event":"restored"' logs/fenced-B.log
{"event":"restored","time":"2026-11-06T23:39:41.598108+00:00","mono_ns":302083341168125,"pid":32466,"worker":"B","epoch":2,"next_row":10000}
volkov@MacBook-Air-Vladimir-2 zk-homework % grep '"event":"publication_rejected"' logs/fenced-A.log
{"event":"publication_rejected","time":"2026-11-06T23:40:22.507406+00:00","mono_ns":302124251194583,"pid":32458,"worker":"A","epoch":1,"error":"BadVersionError"}
volkov@MacBook-Air-Vladimir-2 zk-homework % grep '"event":"записал результат"' logs/fenced-A.log logs/fenced-B.log
logs/fenced-B.log:{"event":"записал результат","time":"2026-11-06T23:39:55.110239+00:00","mono_ns":302096853527958,"pid":32466,"worker":"B","epoch":2,"pointer_version":1}
```

Рисунок 9 — Восстановление B и отклонение устаревшей публикации A


```
volkov@MacBook-Air-Vladimir-2 zk-homework % cat logs/33-fenced-final.txt
{
  "run": "fenced",
  "fencing": 1,
  "pointer_version": 1,
  "pointer": {
    "worker": "B",
    "epoch": 2,
    "csv": "results/fenced/db3fb5953e52b8316ce2c1e9d158e1e1b356bdc0f88e487505ce4bb94f2b61f9.csv",
    "source_rows": 68770,
    "selected_rows": 869,
    "unique_pairs": 6800,
    "pair_contributions": 13468,
    "sha256": "db3fb5953e52b8316ce2c1e9d158e1e1b356bdc0f88e487505ce4bb94f2b61f9",
    "equal_to_hw3": true
  },
  "csv_equal_to_hw3": true,
  "failover_seconds": 11.510106125,
  "accepted_writes": 1,
  "stale_publication_rejected": true,
  "pause_seconds": 40.162820542
}
```


Рисунок 10 — Итог опыта fenced с одной публикацией и указателем B

Время смены лидера составило 11,510 с, длительность паузы — 40,163 с. Принята одна публикация, версия указателя равна 1. Проверка CSV также вернула true. Подтверждения: logs/fenced-A.log, logs/fenced-B.log и logs/33-fenced-final.txt.

10 Сравнение результатов

Показатель	FENCING=0	FENCING=1
Время смены координатора	11,095 с	11,510 с
Длительность паузы A	40,157 с	40,163 с
Успешных публикаций	2	1
Версия указателя	2	1
Автор указателя и эпоха	A, эпоха 1	B, эпоха 2
Старая публикация A	Принята	BadVersionError

Время смены координатора вычислял как разность time.monotonic_ns() для события became_leader у B и момента отправки SIGSTOP процессу A, с переводом наносекунд в секунды. Это время получения лидерства, а не завершения расчёта. Его отличие от 10 секунд связано с моментом последнего heartbeat и обработкой истечения сессии.

11 Ответы на вопросы

Почему три сервера, а не два и не четыре?

Для работы нужно строгое большинство. Из двух серверов нужны оба, поэтому один отказ останавливает ансамбль. Из трёх достаточно двух — один отказ переносится. У четырёх большинство равно трём: выдерживается всё ещё только один отказ, хотя ресурсов требуется больше. Поэтому три сервера — минимальный вариант для переноса одного отказа; для двух отказов нужны пять.

Почему эпоху проверяет получатель записи?

Удаление эфемерного узла не останавливает старый процесс. После возобновления он может открыть новую сессию и отправить поздний запрос, сохранив старую эпоху. Поэтому получатель должен отклонять такую запись. В моей реализации защищаемый ресурс — указатель result в ZooKeeper: функция publish передаёт проверку версии epoch и обновление result одной транзакцией multi. Если версия устарела, вся транзакция откатывается с BadVersionError. Для внешней БД проверку и запись нужно выполнять атомарно средствами самой БД; выбор лидера в ZooKeeper этого автоматически не обеспечивает.

CSV именуется по SHA256 содержимого. Число публикаций определяется обновлениями указателя и строками журнала. Выбор лидера позволил продолжить расчёт с чекпоинта, а проверка эпохи сохранила указатель нового лидера после возобновления старого.

Использованная документация

Apache ZooKeeper 3.9.6 Administrator’s Guide — https://zookeeper.apache.org/doc/r3.9.6/zookeeperAdmin.html
Apache ZooKeeper 3.9.6 Programmer’s Guide — https://zookeeper.apache.org/doc/r3.9.6/zookeeperProgrammers.html
Kazoo 2.11.0 — https://kazoo.readthedocs.io/en/stable/api/client.html